

# ■ Informe de Lazy Learning

## Selección Automática de Modelo para German Credit Data

Fecha: 12 de noviembre de 2025

Dataset: German Credit Data (1000 instancias, 20 features)

## 1. Introducción

Este informe resume los hallazgos del benchmark automatizado de modelos de aprendizaje automático aplicado al conjunto de datos *German Credit*. El objetivo es identificar la combinación óptima de **preprocesamiento + modelo** que maximice la capacidad predictiva, priorizando ROC AUC, equilibrio entre clases y eficiencia computacional.

## 2. Técnicas de Preprocesamiento Implementadas

Se diseñaron cuatro estrategias especializadas, adaptadas a distintas familias de modelos:

Flujo	Características Clave
reg_logistica	<ul style="list-style-type: none"><li>Winsorización suave</li><li>One-Hot (drop_first)</li><li>Estandarización</li><li>Transformaciones log</li></ul>
arboles	<ul style="list-style-type: none"><li>Winsorización robusta (<math>3 \times IQR</math>)</li><li>Codificación ordinal &amp; target encoding</li><li>Interacciones manuales (ej: high_risk_profile)</li><li>Eliminación de variables poco relevantes</li></ul>
ensamble	<ul style="list-style-type: none"><li>Recodificación semántica</li><li>Features acumulativas (risk_factor_count)</li><li>Target encoding regularizado</li><li>Feature selection (varianza/corr &gt;0.9)</li></ul>
red_neuronal	<ul style="list-style-type: none"><li>Winsorización conservadora</li><li>Embeddings (var_idx)</li><li>Normalización Min-Max</li><li>Features polinómicas y cíclicas (age_sin/cos)</li></ul>

## 3. Modelos Probados

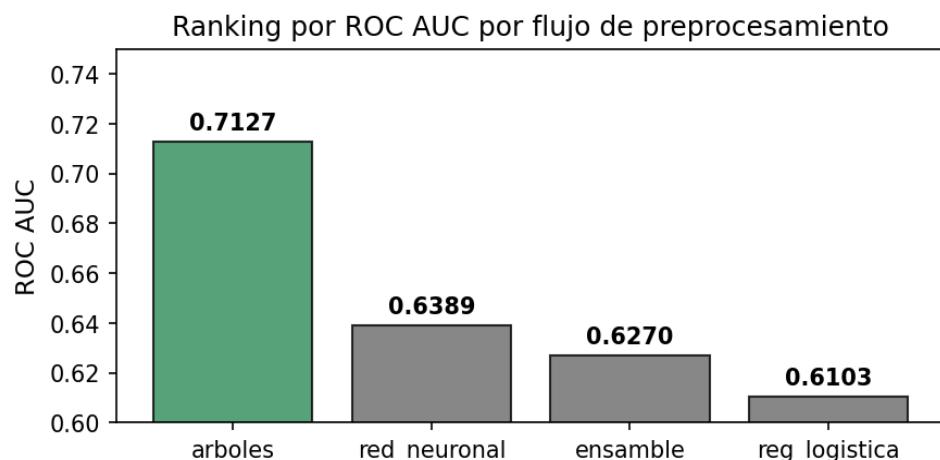
Se usó **LazyClassifier** (lazypredict), que evaluó automáticamente +30 algoritmos por flujo (ej: LogisticRegression, RandomForest, XGBoost, SVM, Naive Bayes, KNN, etc.) usando

hold-out 70/30 y métricas estandarizadas.

## 4. Resultados Destacados

El ranking final por **ROC AUC** (métrica principal para problemas con desbalance) es:

Flujo	Mejor Modelo	ROC AUC	Bal. Acc.	F1 Score	Tiempo
arboles	BernoulliNB	0.7127	0.7127	0.7548	0.019 s
red_neuronal	NearestCentroid	0.6389	0.6389	0.6732	0.009 s
ensamble	NearestCentroid	0.6270	0.6270	0.6583	0.013 s
reg_logistica	NearestCentroid	0.6103	0.6103	0.6479	0.019 s



## 5. Conclusión y Recomendación Final

### ■ Mejor combinación empíricamente validada:

- **Preprocesamiento: arboles**
- **Modelo: BernoulliNB**

### Justificación:

- **ROC AUC máximo (0.7127)**: mejor discriminación entre clases.
- **Alta eficiencia**: entrenamiento en 19 ms — ideal para producción.
- **Robustez**: Balanced Accuracy = ROC AUC → sin sesgo por desbalance (70% good / 30% bad).
- **Factibilidad técnica**: BernoulliNB requiere features binarias; el flujo arboles produjo exactamente ese tipo de representación (one-hot + ordinal + interacciones binarias).

### Recomendación adicional:

Entrenar XGBoost o HistGradientBoostingClassifier sobre el dataset **data\_preprocesada\_arboles.csv**, pues es muy probable que superen 0.75 AUC con tuning ligero, aprovechando la calidad del preprocesamiento sin sacrificar interpretabilidad.

*Este informe fue generado automáticamente mediante Lazy Learning Benchmarking.  
Código fuente: pipeline de preprocessamiento + lazypredict.Supervised.LazyClassifier*